

Práctica 4: Explotar el potencial de las arquitecturas modernas

NOTA: Leer detenidamente el enunciado de cada ejercicio antes de proceder a su realización.

El objetivo de esta práctica es experimentar y aprender a sacar partido a las arquitecturas *multicore* (o *manycore*) a través del *framework* de programación OpenMP [1].

Todo el trabajo asociado a esta práctica se realizará en entorno Linux. Para ello el estudiante puede emplear los ordenadores de los laboratorios, o bien el clúster de docencia de la asignatura. También será posible emplear un ordenador propio. En cualquiera de los casos, es necesarios comunicar en qué equipo/s se han desarrollado las pruebas.

MATERIAL DE PARTIDA

Junto con el enunciado de la práctica, se entrega un fichero, "MaterialP4.zip", que contiene los siguientes ficheros que serán referenciados a lo largo del enunciado:

- `omp1.c` – fichero con el código de ejemplo de un programa que crea hilos utilizando OpenMP. El número de hilos creados se pasa como argumento al programa.
- `omp2.c` – fichero con el código de ejemplo de un programa que muestras las diferencias en la declaración de la privacidad de variables en OpenMP.
- `pescalar_serie.c` – fichero con un código serie que realiza el producto escalar de dos vectores.
- `pescalar_par1.c` y `pescalar_par2.c` – ficheros con el código de ejemplo de programas que realizan paralelización de bucles con OpenMP
- `Makefile` – fichero makefile utilizado para compilar todos los ficheros de código fuente.
- `pi_serie.c` – fichero con un código serie que realiza el cálculo de pi por integración numérica.
- `pi_par1.c` a `pi_par7.c` – ficheros con el código de variantes en OpenMP para calcular pi por integración numérica.

IMPORTANTE

A lo largo de este documento se hará referencia a un número P que afectará a los experimentos y resultados que se obtendrán. El valor de P que debe utilizar debe ser igual al número de pareja módulo 8 más 1 (es decir será un número entre 1 y 8).

Ejercicio 0: información sobre la topología del sistema

En primer lugar, deberíamos de ser capaces de obtener la información relativa a la arquitectura de la máquina sobre la que estamos trabajando. Esto es sencillo en un sistema Linux y podemos hacerlo ejecutando cualquiera de los siguientes comandos:

```
> cat /proc/cpuinfo
```

```
> dmidecode
```

NOTA: este comando requiere permisos de superusuario, por lo que NO podremos utilizarlo en la instalación de los laboratorios.

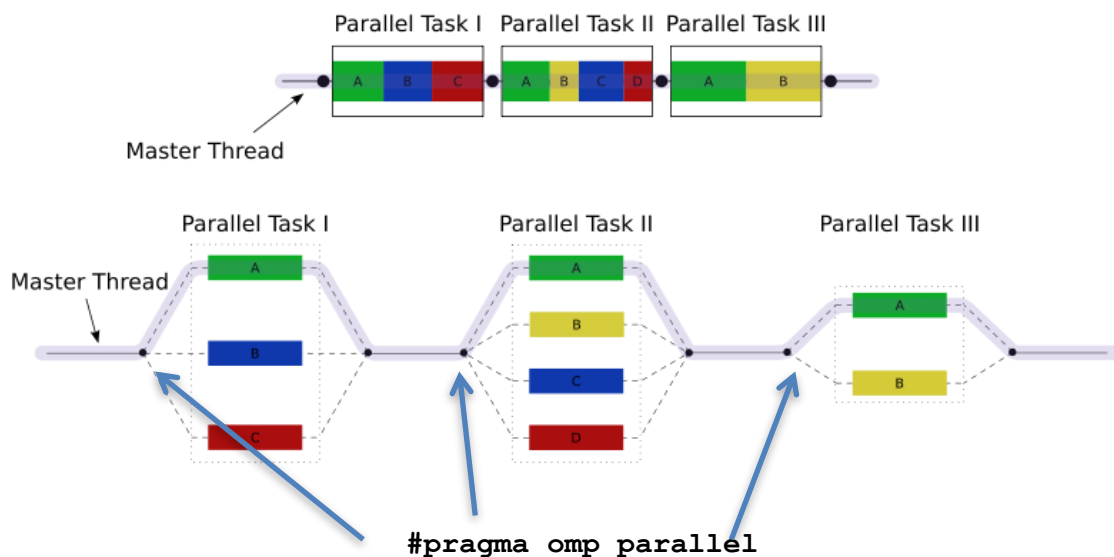
En particular, si nos fijamos en la información que nos da el fichero `cpuinfo` podemos deducir cuántos *cores* tiene nuestro equipo y si tiene o no habilitado la opción de *hyperthreading* (el parámetro `cpu_cores` indica cuántas CPUs físicas hay en equipo, y el parámetro `siblings` hace referencia al número de CPUs virtuales).

A partir de la información expuesta, indique en la memoria asociada a la práctica los datos relativos a las cantidad y frecuencia de los procesadores disponibles en el equipo empleado, y a si la opción de *hyperthreading* está o no activa.

Ejercicio 1: Programas básicos de OpenMP (2 p)

En este ejercicio, vamos a realizar una primera toma de contacto con programas basados en OpenMP. Para realizar la compilación de estos programas utilizaremos como compilador `gcc`, añadiendo las banderas `-lgomp` y `-fopenmp` para indicarle que queremos utilizar las librerías y extensiones de OpenMP.

OpenMP nos permite lanzar de una forma muy sencilla un número de hilos (o *threads*) para que lleven a cabo tareas de forma paralela (cada hilo ejecutando en su CPU correspondiente). La creación de un equipo de hilos se lleva a cabo cada vez que se incluye en la directiva `#pragma omp parallel` en el programa, y la sincronización y finalización de los hilos se realiza al terminar la región paralela señalada con el `parallel`.



En el material de partida, se pide compilar y ejecutar el programa `omp1.c` para comprobar cómo se lleva a cabo el lanzamiento de equipos de hilos, y familiarizarse con las funciones `omp_get_num_threads()` y `omp_get_thread_num()` que nos permiten identificar a cada uno de los *threads* en activo.

- 1.1 ¿Se pueden lanzar más threads que cores tenga el sistema? ¿Tiene sentido hacerlo?
- 1.2 ¿Cuántos threads debería utilizar en los ordenadores del laboratorio? ¿y en el clúster? ¿y en su propio equipo?

Una característica fundamental a la hora de programar utilizando OpenMP es definir correctamente qué variables han de ser públicas (accesibles a todos los hilos, es el valor por defecto) o privadas (cada hilo accede a su propia copia). Un ejemplo de la utilización de estas características puede encontrarse en el programa `omp2.c`.

Se pide ejecutar el programa `omp2` e incluir la salida en la memoria de la práctica. En base a la salida obtenida (y tras leer y comprender el código fuente que la genera) conteste a las siguientes preguntas:

- 1.3 ¿Cómo se comporta OpenMP cuando declaramos una variable privada?
- 1.4 ¿Qué ocurre con el valor de una variable privada al comenzar a ejecutarse la región paralela?
- 1.5 ¿Qué ocurre con el valor de una variable privada al finalizar la región paralela?
- 1.6 ¿Ocurre lo mismo con las variables públicas?

Ejercicio 2: Paralelizar el producto escalar (3 p)

Tomaremos como código de referencia el del producto escalar, cuya versión serie y dos versiones paralelas se entregan como material de partida de la práctica. OpenMP está especialmente pensado para realizar la paralelización del trabajo de un bucle *for* entre los hilos del equipo. Cuando se quiere repartir el trabajo de un bucle de esta forma se utiliza la cláusula `#pragma omp parallel for`. Al indicar esta cláusula, OpenMP ya hace trabajo por nosotros como por ejemplo declarar como privada la variable que se utiliza como índice del bucle.

Ejecute la versión serie y las dos versiones paralelas del producto escalar y observe el resultado numérico obtenido. Conteste en la memoria a las siguientes preguntas:

- 2.1 ¿En qué caso es correcto el resultado?
- 2.2 ¿A qué se debe esta diferencia?

Tomando ahora únicamente la ejecución de la versión serie y la versión paralela que da el resultado correcto, se pide hacer un análisis del rendimiento obtenido en el problema del producto escalar para diferente número de hilos: de 1 a C, siendo C el número de cores del equipo empleado. Analice cómo varía la aceleración obtenida para vectores de diferentes tamaños.

NOTA: Elija al menos 10 tamaños diferentes y para elegirlos siga por ejemplo el siguiente criterio: busque que el tiempo de ejecución del programa serie para el experimento de mayor tamaño se corresponda con 10 segundos y para el de menor tamaño sea de 0,1 segundo. Repita cada medida al menos 5 veces.

La presentación de estos resultados se deberá incluir en la memoria de la práctica representando en una gráfica los tiempos de ejecución y en otra la aceleración obtenida en función del tamaño del vector.

Teniendo en cuenta los resultados obtenidos, se pide contestar justificadamente las siguientes preguntas:

- 2.3 En términos del tamaño de los vectores, ¿compensa siempre lanzar hilos para realizar el trabajo en paralelo, o hay casos en los que no?
- 2.4 Si compensara siempre, ¿en qué casos no compensa y por qué?
- 2.5 ¿Se mejora siempre el rendimiento al aumentar el número de hilos a trabajar?
- 2.6 Si no fuera así, ¿a qué debe este efecto?
- 2.7 Valore si existe algún tamaño del vector a partir del cual el comportamiento de la aceleración va a ser muy diferente del obtenido en la gráfica.

Ejercicio 3: Paralelizar la multiplicación de matrices (3 p)

Para este ejercicio se tomará como código de partida el de la multiplicación de matrices que cada alumno ha desarrollado a lo largo de la práctica 3 de la asignatura.

En este caso, el programa se compone de tres bucles anidados, por lo que a la hora de llevar a cabo la paralelización del trabajo a realizar es razonable preguntarse: ¿cuál de los bucles interesa paralelizar?

Se pide desarrollar y entregar (además de la versión serie de la práctica 3) tres versiones paralelas de la multiplicación de matrices paralelizando los tres bucles existentes. Las versiones entregadas han de funcionar de forma correcta.

Se pide rellenar las siguientes tablas realizando la ejecución para matrices de tamaño suficientemente grande para que los valores de tiempo de ejecución permitan ver diferencias entre los diferentes casos que se estudien (por ejemplo, empiece evaluando un tamaño de 1000x1000 que tarden unos 10 segundos y pruebe al menos otro tamaño que tarde 60 segundos):

Tiempos de ejecución (s)

Versión\# hilos	1	2	3	4
Serie				
Paralela – bucle1				
Paralela – bucle2				
Paralela – bucle3				

Speedup (tomando como referencia la versión serie)

Versión\# hilos	1	2	3	4
Serie	1			
Paralela – bucle1				
Paralela – bucle2				
Paralela – bucle3				

NOTA: se considera que el bucle 1 es el más interno, el bucle 2 es el bucle intermedio, y el bucle 3 es el bucle más externo. En el caso serie completar sólo la columna para un hilo.

Teniendo en cuenta los resultados obtenidos, conteste a las siguientes preguntas:

- 3.1 ¿Cuál de las tres versiones obtiene peor rendimiento? ¿A qué se debe?
- 3.2 ¿Cuál de las tres versiones obtiene mejor rendimiento? ¿A qué se debe?


Tomando como referencia los tiempos de ejecución de la versión serie y el de la mejor versión paralela obtenida anteriormente (la mejor combinación entre las tres versiones de código, y las C posibilidades para el número de hilos paralelos). Tome tiempos en un fichero y realice una gráfica de la evolución del tiempo de ejecución y la aceleración (de la versión paralela vs serie) al ir variando el tamaño de las matrices de NxN para N entre 512+P y 1024+512+P (con incrementos en N de 64). Tras incluir estas dos gráficas en la memoria, incluya un párrafo describiendo y justificando el comportamiento observado en las mismas.

- 3.3 Si en la gráfica anterior no obtuvo un comportamiento de la aceleración en función de N que se estabilice o decrezca al incrementar el tamaño de la matriz, siga incrementando el valor de N hasta conseguir una gráfica con este comportamiento e indique para que valor de N se empieza a ver el cambio de tendencia.

Ejercicio 4: Ejemplo de integración numérica (3 p)

El ejemplo con el que vamos a trabajar a lo largo de esta sesión consiste en obtener una aproximación del valor del número π mediante una integración numérica. En particular, vamos a calcular el área encerrada por una función f en el intervalo $[0,1]$ aproximando dicha área mediante rectángulos con anchura igual a h y altura igual a $f(x)$.

$$\int_0^1 \frac{4}{1+x^2} dx = 4 \int_0^1 \frac{1}{1+x^2} dx = 4 [\tan^{-1}(1) - \tan^{-1}(0)] = 4 \left[\frac{\pi}{4} - 0 \right] = \pi$$



Cuanto más estrechos sean estos rectángulos, mayor será la aproximación al resultado real y por tanto al número π . Un ejemplo de programa que realiza esta tarea puede encontrarse en el fichero `pi_serie.c` que se encuentra en la carpeta de material de para la práctica.

Pregunta 4.1: ¿Cuántos rectángulos se utilizan en la versión del programa que se da para realizar la integración numérica?

Perdida de rendimiento por el efecto de falso compartir (*False sharing*) en OpenMP

En el material de partida se encuentran varias versiones paralelas del algoritmo comentado anteriormente. Fíjese concretamente en las versiones pi_par1.c y pi_par4.c.

Pregunta 4.2: ¿Qué diferencias observa entre estas dos versiones?

Ejercicio 4.3: Ejecute las dos versiones recién mencionadas. ¿Se observan diferencias en el resultado obtenido? ¿Y en el rendimiento? Si la respuesta fuera afirmativa, ¿sabría justificar a qué se debe este efecto?

En los programas pi_par2.c y pi_par3.c se incorporan dos modificaciones distintas sobre la versión 1 para intentar obtener un rendimiento similar a la versión 4.

Ejercicio 4.4: Ejecute las versiones paralelas 2 y 3 del programa. ¿Qué ocurre con el resultado y el rendimiento obtenido? ¿Ha ocurrido lo que se esperaba?

Ejercicio 4.5: Abra el fichero pi_par3.c y modifique la línea 32 del fichero para que tome los valores fijos 1, 2, 4, 6, 7, 8, 9, 10 y 12. Ejecute este programa para cada uno de estos valores. ¿Qué ocurre con el rendimiento que se observa?

Ejercicio 5: Uso de la directiva `critical` y `reduction` (1 punto)

En el fichero `pi_par5.c` se encuentra una versión que intenta resolver el problema de la falsa compartición mediante el uso de variables privadas y la creación de una sección crítica.

Ejercicio 5.1: Ejecute las versiones 4 y 5 del programa. Explique el efecto de utilizar la directiva `critical`. ¿Qué diferencias de rendimiento se aprecian? ¿A qué se debe este efecto?

Ejercicio 5.2: Ejecute las versiones 6 y 7 del programa. Explique el efecto de utilizar las directivas utilizadas. ¿Qué diferencias de rendimiento se aprecian? ¿A qué se debe este efecto?

MATERIAL A ENTREGAR

Memoria con las respuestas a las preguntas a lo largo del enunciado.

En subdirectorios independientes, los ficheros con los datos obtenidos en los experimentos de los ejercicios que así lo indiquen, y los scripts utilizados para la obtención de estos datos (si se ha usado alguno).

Códigos fuente desarrollados para la resolución del ejercicio 3.

La entrega se realizará a través de moodle, con fecha límite el día antes de la realización del examen correspondiente a las prácticas 3 y 4.

MATERIAL DE REFERENCIA

[1] OpenMP: Tutorials and technical articles <http://openmp.org/wp/resources/#Tutorials>